

Биостатистика – Пројектни задатак

Име и презиме: Ведран Продановић

Број индекса: 0088/2022

У оквиру Теамс фолдера где се налази овај пројектни задатак пронаћи ћете матрицу *Arcadis.xlsx* над којом је потребно спровести различите статистичке анализе у следећим задацима: 1, 2, 3, 4, и 5. Такође, у задацима 6, 7 и 8 потребно је искористити матрице које се у њима наводе, а које су доступне у истом фолдеру.

Матрица *Arcadis.xlsx* садржи категоријске варијабле:

- *Continent* за коју су дате вредности 1, 2 и 3 које означавају континенте Европу, Северну Америку и Азију, респективно.

НАПОМЕНА: у свим задацима где је потребно обезбедити квази-рандомизацију, потребно је употребити функцију `set.seed(123)`.

Задатак 1 Употребом регуларизационе методе *RIDGE* предвидите туристички индекс *Tourism* на основу варијабли *education, crime, health, affordability, Energy* и *Greenspace*. Затим, одговорите на постављена питања. Претпоставите да су предиктори стандардизовани (стандардизацију обично ради *glmnet* аутоматски, осим ако није другачије задано).

Наведите две главне разлике између *LASSO* (L1) и *Ridge* (L2) регресије.

Одговор: *LASSO* своди коефицијенте мање битних варијабли тачно на нулу, док их *Ridge* само приближава нули, али их никада не елиминише у потпуности. *LASSO* користи L1 норму (сума апсолутних вредности), док *Ridge* користи L2 норму (сума квадратних коефицијената).

Зашто је потребно стандардизовати променљиве пре *Ridge/LASSO* анализа?

Одговор: Зато што су казнени чланови (L1 и L2) осетљиви на мерну јединицу варијабли. Ако варијабле немају исту мерну јединицу, варијабле са већим опсегом вредности имаће несразмерно већи утицај на кажњавање.

Којим линијама кода се може учитати *Arcadis.xlsx* и направити матрицу X са наведеним променљивима и вектор одзива $y = \text{Tourism}$?

```
arcadis <- read_excel("Arcadis.xlsx")
predictors <- c("education", "crime", "health", "affordability", "Energy", "Greenspace")
X <- as.matrix(arcadis[, predictors])
y <- arcadis$Tourism
```

Примените *Ridge* са *cross-validation* техником, при чему треба водити рачуна да је неопходно

обезбедити квази-рандомизацију применом функције `set.seed(123)`. Тада ће

параметри модела бити `cv.glmnet(X, y, alpha = 0, family = "gaussian", type.measure = "mse", standardize = T, nfolds = 10)`, док је минимално λ , заокружено на

четири децимале, једнако 0.2422.

Када је испуњен услов $\lambda = \lambda_{\min}$ број променљивих које се задржавају у моделу је 6, а у

питању су променљиве *education, crime, health, affordability, Energy, Greenspace*.

Одредите вредност *lambda.1se* за *Ridge* модел: 102.4271.

Користећи *Ridge* модел са λ_{min} , израчунајте предикције за све градове и пронађите 5 градова са највећом апсолутном грешком $|Tourism - pred_Tourism|$. Попуните одговарајућим вредностима следећу табелу: *City*, *Tourism*, *pred_Tourism*, *abs_err*. *pred_Tourism* представља предвиђену (*fitted*) вредност варијабле *Tourism* за сваки град, добијену применом *Ridge* регресионог модела при $\lambda = \lambda_{min}$.

City	Tourism	pred_Tourism	abs_err
Kuala Lumpur	0.942	0.3245846	0.6174154
Paris	0.972	0.3628806	0.6091194
Bangkok	0.942	0.3342399	0.6077601
Istanbul	0.750	0.1819496	0.5680504
Macau	1.002	0.4413317	0.5606683

Издвојите само градове који су на континентима *Europe* и *Asia*, и који имају *crime* изнад медијане (медијана се рачуна на целом скупу).

На том подскупу *fit*-ујте *Ridge* (*cv.glmnet*, λ_{min}), израчунајте *pred_Tourism* и *abs_err*, па затим (помоћу *for* петље) за сваки од два континента извуците топ 3 града са највећом *abs_err*.

Continent	City	Tourism	pred_Tourism	abs_err
Europe	Geneva	0.042	0.4806549	0.4386549
Europe	London	0.972	0.5396737	0.4323263
Europe	Rome	0.828	0.4094665	0.4185335
Asia	Macau	1.002	0.4064651	0.5955349
Asia	Shenzhen	0.888	0.4887551	0.3992449
Asia	Hong Kong	1.002	0.6172783	0.3847217

Задатак 2

а) Испитати да ли постоји разлика у вредностима варијабле *Easeofdoingbusiness* ако посматрамо градове у Европи и Азији.

Први корак у анализи је да спроведемо Shapiro – Wilk тест.

Нулта хипотеза Варијабла *Easeofdoingbusiness* је нормално расподељена.

Алтернативна хипотеза Варијабла *Easeofdoingbusiness* није нормално расподељена.

Вредности статистика су 0.95311 и 0.84781, док су p вредности респективно 0.1766 и 0.002484.

Закључујемо да је алтернативна хипотеза важећа за други узорак,

па за испитивање разлика користимо Mann – Whitney U тест.

На основу добијених резултата тумачимо резултате теста

Нулта хипотеза: Оба узорка долазе из исте популације.

Алтернативна хипотеза: Оба узорка не долазе из исте популације.

Вредност статистике је -3.7386, док је p вредност 1.85e-4.

Нулту хипотезу **ОДБАЦУЈЕМО** ПРИХВАТАМО

ЗАКЉУЧАК: Постоји значајна статистичка разлика у вредностима варијабле *Easeofdoingbusiness* између градова у Европи и Азији.

б) Извојите само градове из Европе и Азије који имају *Greenspace* изнад медијане (медијана се рачуна на целом скупу).

На том подскупу, за сваку од променљивих *crime*, *health* и *Energy* формирајте табелу са резултатима испитивања разлика између задатих група. У табели приказати (испуњеност критеријума нормалности уз референтну p -value + који тест је коришћен + статистика и p -value коришћеног теста).

<i>Variable</i>	<i>Shapiro_p_Euro</i>	<i>Shapiro_p_Asia</i>	Коришћени тест	<i>p_value</i>	<i>Test statistic</i>
<i>crime</i>	$p\text{-value} = 0.217185 > 0.05$; Испуњен	$p\text{-value} = 0.001431 < 0.05$; Није испуњен	Mann – Whitney U	1	0
<i>health</i>	$p\text{-value} = 0.072261 > 0.05$; Испуњен	$p\text{-value} = 0.044219 < 0.05$; Није испуњен	Mann – Whitney U	0.9488	-0.064189
<i>Energy</i>	$p\text{-value} = 0.083699 > 0.05$; Испуњен	$p\text{-value} = 0.002567 < 0.05$; Није испуњен	Mann – Whitney U	2.049e-5	-4.2595

ц) Формирајте подскуп који садржи само *Europe* и *North America* градове са *affordability* у првом квинтилу. Затим, за три прага *crime* (0.8, 0.9, 0.95) правите додатни подскуп *crime* < праг и за сваки праг тестирајте разлику у *Tourism* између *Europe* и *North America*. Резултате приказати у следећој табели.

<i>Crime праг</i>	<i>n_Europe</i>	<i>n_North America</i>	<i>Shapiro_p_ Europe</i>	<i>Shapiro_p_ NorthAmerica</i>	Коришћени тест	<i>p_value</i>
0.8	0	12	/	0.007780809	/	/
0.9	0	15	/	0.001031624	/	/
0.95	2	15	/	0.001031624	Mann – Whitney U	0.052487

Задатак 3: Испитати да ли постоји разлика у вредностима варијабле *Connectivity* у зависности од континента на коме се град налази.

Први корак у анализи је да спроведемо Shapiro – Wilk тест.

Нулта хипотеза Варијабла *Connectivity* је нормално расподељена.

Алтернативна хипотеза Варијабла *Connectivity* није нормално расподељена.

Вредности статистика су 0.97397, 0.93577 и 0.90948, док су p вредности респективно 0.6154, 0.1618 и 0.03983.

Закључујемо да је алтернативна хипотеза важећа за трећи узорак,

па за испитивање разлика користимо Kruskal – Wallis тест.

На основу добијених резултата тумачимо резултате теста

Нулта хипотеза: Не постоји статистички значајна разлика у медијанама посматране варијабле између тестираних група.

Алтернативна хипотеза: Постоји статистички значајна разлика у медијани посматране варијабле између најмање две групе.

Вредност статистике је 18.8, док је p вредност 8.272e-5.

Нулту хипотезу **ОДБАЦУЈЕМО** ПРИХВАТАМО

ЗАКЉУЧАК: Постоји статистички значајна разлика у медијани варијабле *Connectivity* између најмање два континента.

Издвојите градове који истовремено испуњавају услов: *Greenspace* > медијана (рачуната на целом скупу), па на том подскупу, испитајте да ли постоји разлика у *Tourism* између континената.

Shapiro-Wilk p -value за Европу, Северну Америку и Азију су: 0.0834348, 0.0929907, 0.0646849.

Изабрани тест је: ANOVA, а добијена p -value теста 0.388.

Post-hoc тест који можемо спровести је /, са методом /.

Овим тестом се показује да постоје разлике између континената

Не постоје статистички значајне разлике ни између једног пара континената, јер
су припадајуће p-values веће од 0.05 (главни ANOVA тест није значајан, $p > 0.05$).

Задатак 4. Коришћењем методе *K-medoids*, потребно је кластеризовати градове према различитим димензијама, а у односу на следеће варијабле: *health*, *affordability*, *Energy*, *Easeofdoingbusiness* и *Connectivity*. Одаберите $k = 3$. Након кластеровања, профилишите кластере, израчунајте просечне вредности свих коришћених индикатора у сваком кластеру.

Приликом спровођења *K-medoids* методе, бирају се апстрактне/**стварне** опсервације које овој методи обезбеђују **већу**/мању робустност у односу на *K-means* методу, јер су на овај начин кластери више/**мање** осетљиви на екстремне вредности у подацима.

Приликом спровођења *K-medoids* методе, подразумевана метрика за рачунање одстојања је

Euclidean метрика. Ако би било потребно употребити *Manhattan метрику*, онда се прво мора направити матрица растојања помоћу функције `dist(..., method = "manhattan")`, а затим се

позива функција `pam(..., diss = TRUE)` са одговарајућим параметрима.

Број градова у првом, другом и трећем кластеру је 37, 19, 21, респективно.

Медоиди првог, другог и трећег кластера, респективно, су градови Munich, Shenzhen и Houston.

Метрика која се користи за интерпретацију ваљаности спроведене кластеризације зове се просечна ширина силуete, а у случају спроведеног модела вредност те метрике се чита помоћу функције `pam(..., k = 3, metric = "euclidean")$silinfo$avg.width`, а вредност је 0.3818896.

Кластер са најмањом просечном вредношћу варијабле *health* је кластер чији је медоид град Houston а та вредност је 0.547333.

Кластер са највећом просечном вредношћу варијабле *Energy* је кластер чији је медоид град Munich а та вредност је 0.659703.

Кластер са најмањом просечном вредношћу варијабле *Connectivity* је кластер чији је медоид град Shenzhen а та вредност је 0.336316.

Издвојите само градове који испуњавају услове: $Tourism > \text{медијана}(Tourism)$ на целом скупу и $crime < \text{медијана}(crime)$ на целом скупу. На том подскупу спроведите $ram()$ ($k = 3$, $metric = "euclidean"$) над 5 индикатора одабраних на почетку. Затим, за сваки кластер, користећи for петљу, пронађите град који је најудаљенији од свог медоида и попуните следећу табелу:

Кластер	Медоид	Најудаљенији град	Растојање до њега	Број градова у кластеру
1	Taipei	Antwerp	0.314116	6
2	Warsaw	Istanbul	0.403453	6
3	San Francisco	New York	0.131594	2

Издвојите само градове који имају $health > \text{медијана}(health)$ на целом скупу. На том подскупу урадите $ram()$ ($k = 3$, $metric = "euclidean"$). Затим, за сваки континент посебно, израчунајте:

- који је доминантан кластер (онај који у себи садржи највише градова тог континента),
- колики је удео доминантног кластера унутар тог континента,
- и укупан број градова у континенту (n_{total}).

Резултате прикажите попуњавањем следећих табела:

Табела. Расподела градова по кластерима у односу на припадајуће континенте

Континент	1. кластер	2. кластер	3. кластер
Европа	15	9	0
Северна Америка	1	0	0
Азија	5	0	8

Табела. Преглед доминантних кластера по континентима

Континент	Доминантни кластер	Удео	Укупно градова на континенту
Европа	1	62.50%	24
Северна Америка	1	100.00%	1
Азија	3	61.54%	13

Након спроведене *K-medoids (PAM)* кластеризације са бројем кластера $k = 3$, потребно је упоредити резултате добијене применом **две различите метрике растојања** над истих пет индикатора (*health, affordability, Energy, Easeofdoingbusiness u Connectivity*): еуклидске метрике и *Manhattan* метрике. За еуклидску метрику *PAM* се примењује директно на матрицу података, док се за *Manhattan* метрику најпре конструише матрица растојања помоћу функције *dist(..., method = "manhattan")*, а затим се функција *pam()* позива са аргументом *diss = TRUE*. Кроз *for* петљу потребно је за оба модела израчунати две мере квалитета кластеризације: просечну вредност силуетног индекса (*avg.width*), која показује колико су кластери добро развојени, и финалну вредност *objective* функције, која представља укупно растојање унутар кластера. На основу добијених вредности, резултате треба приказати у табели и закључити који модел је бољи, а затим навести и имена градова који су идентификовани као медоиди у том бољем моделу.

Резултати:

Метрика	<i>avg_sill_score</i>	<i>Objective score</i>
<i>Euclidean</i>	0.3818896	0.2405389
<i>Manhattan</i>	0.3952924	0.4292468

Боља метрика је Manhattan, зато што има већу вредност просечног силуетног индекса.

Медоиди добијени помоћу боље метрике јесу: Munich, Miami, Macau.

Задатак 5. Коришћењем методе факторске анализе смањити димензионалност дате матрице података и одговорити на следеће захтеве.

Када је потребно спровести чисту редукцију димензије, компресију података или визуализацију без претпоставки о скривеним узроцима, користи се метода **АГК/ФА**. Ако имате велики број корелираних индикатора и треба вам мањи број синтетичких варијабли за кластеровање, регресију или визуализацију, метода **АГК/ФА** је одговарајућа јер **користи**/не користи све варијансе **променљивих**/фактора и **не захтева**/захтева латентни модел.

Када постоји теоријски разлог да иза корелација стоје неколико латентних конструката (фактора), нпр. у психометрији (мерење особина личности), маркетингу или сродним наукама, користи се метода **АГК/ФА**. Метода **АГК/ФА** издваја **заједничку**/сингуларну варијансу и омогућава интерпретацију променљивих/**фактора** као „узрока“ корелација, док **специфичну**/заједничку варијансу третира као шум или мерну грешку.

Израчунајте *p-value* за *Bartlett test of sphericity*: 2.22e-16.

Израчунајте *overall KMO (MSA)*: 0.84.

Уколико је потребно објаснити барем 70% варијабилитета података, узимајући у обзир кумулативне варијансе компоненти добијених из датог скупа података, потребно је изабрати 4 као број фактора за факторску анализу

У факторској анализи, факторско оптерећење је корелација између посматране променљиве и фактора.

У факторској анализи, комуналитет променљиве је пропорција укупне варијансе дате променљиве која је објашњена задржаним факторима.

Применом *varimax* ротације, за задати број фактора, применом факторске анализе добијају се следећи резултати:

На фактору MR1, највеће апсолутно оптерећење има променљива Easeofdoingbusiness са вредношћу 0.92.

Која је променљива најлошије објашњена факторима (има најмању вредност комуналитета) и колика је та вредност? Најмању вредност комуналитета има променљива Tourism и њена вредност износи 0.47.

Комуналитет променљиве *health* износи приближно 0.88, што значи да фактори објашњавају 88 % њене варијансе.

Ако град има висок MR1 скор, а низак скор на *affordability*, очекује се да буде : **високо развијен**/ниско развијен за бизнис, а приступачан/**скуп**.

Фактор са највећом просечном комуналношћу (*average communality*) је фактор MR2, а та вредност износи 0.82. Две променљиве са највећим оптерећењем ($|loading|$) на том фактору, из претходног питања, су health и crime.

Гледајући сваки задржани фактор, пронађите градове који имају највеће вредности за сваки фактор, па у следећу табелу упишите те градове и њихове одговарајуће вредности:

Фактор	Град	Скор
MR1	<i>San Francisco</i>	1.51
MR2	<i>Tokyo</i>	2.45
MR3	<i>Stockholm</i>	1.64
MR4	<i>Macao</i>	3.05

Спроведите факторску анализу са $n_{factors} = 4$ и $rotate = "varimax"$ (обавезно израчунајте *factor scores*). Затим издвојите само градове из Европе који су у горњем квантилу по *Tourism* (односно задовољавају услов: $\geq quantile(..., 0.75)$, рачунато унутар Европе). На том подскупу, уз помоћ *for* петље израчунајте *cor()* између *Tourism* и сваког фактора (*MR1*, *MR2*, *MR3*, *MR4*), па наведите фактор са највећом $|cor|$. Дакле, резултати су редом:

Вредност горњег квантила, на основу које се врши селекција података, износи: 0.5505.

Вредности коефицијента корелације између варијабле *Tourism* и сваког од фактора су: 0.05, -0.16, 0.41, 0.02.

Фактор који има највећи коефицијент корелације јесте MR3 и та вредност је 0.41.

Посматрајте само променљиве *health*, *affordability*, *Energy*, *Easeofdoingbusiness* и *Connectivity*, и за сваки континент посебно спроведите анализу погодности и факторску анализу на следећи начин: најпре израчунајте *p-value Bartlett*-овог теста сферичности, затим одредите укупну *KMO (MSA)* меру адекватности узорка, након чега на основу сопствених вредности (*eigenvalues* > 1) корелационе матрице изаберите број фактора према *Kaiser*-овом критеријуму; потом спроведите факторску анализу са *varimax* ротацијом и за изабрани број фактора идентификујте променљиву са највећим комуналитетом. Добијене резултате (по континентима) уписати у табелу испод.

Континент	<i>n</i>	<i>Bartlett_p</i>	<i>KMO MSA value</i>	<i>n_factors</i>	<i>top_communality _variable</i>	<i>Comm_value</i>
Европа	32	4e-5	0.58702	2	Energy	0.86884
Северна Америка	22	0	0.60971	2	Easeofdoingbusiness	0.94189
Азија	23	0	0.719	1	Easeofdoingbusiness	0.91423

Потребно је да се најпре спроведе факторска анализа над нумеричким променљивама, уз фиксиран број фактора $n_{factors} = 4$, примену *varimax* ротације и израчунавање факторских скорова методом *scores = "regression"*. Затим је неопходно издвојити подскуп градова који се

налазе у горњем квантилу по променљивој *Connectivity* и истовремено у доњем квантилу по променљивој *affordability*, при чему се квантилни прагови рачунају на целом скупу података. На том подскупу треба, коришћењем *for* петље, израчунати просечан факторски скор за сваки фактор и идентификовати фактор код кога је апсолутна вредност тог просека највећа, јер тај фактор најјаче карактерише издвојени подскуп градова. Након тога, за тај изабрани фактор потребно је рангирати градове према вредности њиховог факторског скорa и издвојити пет градова са највећим позитивним вредностима фактора ако је просек позитиван, односно пет градова са најмањим (најнегативнијим) вредностима фактора ако је просек негативан, јер су то градови који највише одступају од нуле у истом смеру као и просечан факторски скор и тиме најјаче испољавају карактеристике тог фактора. Резултати се уписују у табелу која садржи следеће колоне: Град (назив града), Континент (континент на ком се град налази), *Tourism* (вредност туристичког индекса), Одабрани фактор (ознака изабраног фактора, нпр. *MR1*), и *Score* (факторски скор тог града за наведени фактор).

Просечне вредности сваког од фактора (*MR1*, *MR2*, *MR3*, *MR4*) су: 0.73, 1.05, 0.11, 0.49.

Од свих фактора бира се MR2, јер има највећу апсолутну вредност и просек је позитиван.

Ранг	Град	Континент	Вредност варијабле <i>Tourism</i>	Одабрани фактор	<i>Score</i>
1	Tokyo	Asia	0.33	MR2	2.45
2	Hong Kong	Asia	1.00	MR2	1.95
3	Zurich	Europe	0.35	MR2	1.12
4	Geneva	Europe	0.04	MR2	0.90
5	Copenhagen	Europe	0.44	MR2	0.80

Задатак 6. Потребно је учитати библиотеке за рад са методом анализе преживљавања. Успоставите радно окружење тако што ћете инсталирати и учитати *survival*, *survminer* и *readxl*. Базу података *plucaSurvival.xlsx* учитајте, преко функције *read_excel*. Дефинишите догађај (*event*): Креирајте колону *event* као индикатор смрти – вредност 1 када је *status == 2*, иначе 0. Ово омогућава правилну интерпретацију у моделирању.

У бази *plucaSurvival.xlsx* дата је категоријска варијабла пол (1 – мушкарац, 2 – жена). Спровести анализу преживљавања и одговорити на следеће захтеве

У скупу анализираних података, постоји 228 опсервација. Број одиграних догађаја (хазардних догађаја) је 149.

Медијално време преживљавања је 344 временских јединица.

Да би се статистички проверила разлика између полова, спроводи се Log – Rank тест. Статистика овог теста износи 0.9122, док је одговарајућа *p* вредност једнака 0.33953. Закључује се да не постоји значајна разлика у преживљавању између полова.

Зарад потребе провере статистички значајне потврде пола као варијабле са прогностичким фактором преживљавања спроводи се Сох РН модел. Одговарајућа *p* вредност једнака је 0.341. Закључује се да пол није од статистичког значаја као варијабла са прогностичким фактором.

Из спроведеног модела могло би да се претпостави да жене/мушкарци имају 14.82 % мањи/већи ризик од хазардног догађаја у односу на жене/мушкарце.

Креирајте мултиваријантни Сох РН модел који укључује променљиве *sex*, *age* и *ph.ecog*. Допуните:

Вредности $\exp(\text{coef})$ (hazard ratio) за пол је 0.7902949; за узраст је 1.0006038; а за *ph.ecog* је 1.2549784. *P*-вредности су 0.16803 (пол), 0.94931 (узраст) и 0.00817 (*ph.ecog*), а то значи да је модел статистички значајан (Likelihood ratio test $p = 0.0364$), при чему једино *ph.ecog* статистички значајан предиктор ($p < 0.05$), док пол и узраст нису.

Повећање *ph.ecog* за једну јединицу повећава ризик од хазардног догађаја за 25.5 %, јер је $HR =$ 1.2549784.

Жене имају $HR:$ 0.7902949, што значи да имају 20.97 % мањи ризик од мушкараца. Та разлика јесте/није статистички значајна јер је *p*-вредност једнака 0.16803.

Над већ учитаном и сређеном матрицом података, формирајте три старосне групе *AgeGroup* на основу терцила променљиве *age* (групе *Low*, *Medium*, *High*). Спроведите *Kaplan–Meier* анализу по групама и урадите *log-rank* тест да проверите да ли постоји разлика у преживљавању између ове три групе (прикажите *chisq* и *p-value*), а затим за сваку групу израчунајте и прикажите у табели: број пацијената *n*, број догађаја *events*, медијално време преживљавања *median_survival* (у данима) и вероватноћу преживљавања на $t = 365$ (*S_365*); након тога, „најжилавију“ групу дефинишете као ону са највећом медијаном преживљавања, и за њу израчунајте колико је дана „дужа“ њена медијана у односу на преостале две групе ($\text{delta_days} = \text{median_best} - \text{median_other}$), као и колико то износи додатних дана по сваком месецу трајања друге групе, где месец рачунате као 30 дана, тј. $\text{extra_days_per_month} = \text{delta_days} / (\text{median_other} / 30)$ (ове разлике прикажете у посебној табели за поређења најжилавије групе са преостале две).

Према резултату *log-rank* теста ($p = \underline{0.8452775}$), да ли постоји статистички значајна разлика у преживљавању између *AgeGroup* група? Одговор: НЕ (ДА/НЕ)

На нивоу значајности $\alpha = 0.05$, нулту хипотезу „криве преживљавања су исте у све три групе“: НЕ ОДБАЦУЈЕМО (ОДБАЦУЈЕМО / НЕ ОДБАЦУЈЕМО)

Табела 1: Резиме резултата према групама старости *AgeGroup*

AgeGroup	n	events	median_survival	S_365
Medium	<u>76</u>	<u>52</u>	<u>302</u>	<u>0.4040727</u>
Low	<u>76</u>	<u>48</u>	<u>353</u>	<u>0.4693548</u>
High	<u>76</u>	<u>49</u>	<u>361</u>	<u>0.4638404</u>

„Најжилавија група“ је група: High.

Табела 2: Резиме резултата анализе преживљавања између „најжилавије групе“ и других група

Најжилавија Група	Преостала група	Median_days Најжилавија група	Median_days Преостала група	Delta_days	Extra_days_per_month
High	Low	361	353	8	0.689
High	Medium	361	302	59	5.910

Посматрајте само пацијенте који су $sex = "Жена"$ и имају $ph.ecog \leq 1$, а затим унутар тог подскупа дефинишите кандидате за старосни праг ($cutoff$) као квантилане вредности променљиве age добијене за нивое 0.20, 0.30, 0.40, 0.50, 0.60, 0.70 и 0.80. За сваки такав $cutoff$ формирајте бинарну групну променљиву $AgeBin$ са нивоима $age < cutoff$ и $age \geq cutoff$, али у даљу анализу укључите само оне $cutoff$ вредности за које обе групе садрже најмање $n_{min} = 5$ пацијената и најмање $events_{min} = 5$ догађаја (смрти). За сваки важећи $cutoff$ спроведите $log-rank$ тест поређења кривих преживљавања и израчунајте вредности χ^2 статистике ($chisq$) и одговарајуће p_value , након чега као „најбољи“ изаберите онај $cutoff$ који даје највећу $chisq$ вредност. На крају, за изабрани $cutoff$, прикажите за обе старосне групе ($AgeBin < cutoff$ и $AgeBin \geq cutoff$) следеће параметре: број пацијената (n), број догађаја ($events$), медијално време преживљавања ($median_survival$, у данима) и вероватноћу преживљавања у времену $t = 365$ дана ($S(365)$).

Вредност χ^2 статистике $log-rank$ теста за изабрани $cutoff$ износи 0.8641.

Одговарајућа p_value за $log-rank$ тест износи 0.3526.

На основу $log-rank$ теста за оптимални $cutoff = 65$, да ли постоји статистички значајна разлика у преживљавању између две старосне групе ($AgeBin < cutoff$ и $AgeBin \geq cutoff$)?

Одговор: НЕ ПОСТОЈИ (ПОСТОЈИ / НЕ ПОСТОЈИ)

Табеларно упоредно прикажите разлике у $AgeBin$ групама за оптимални $cutoff$ и то према колонама: n , број догађаја, медијално време преживљавања и $S(365)$.

Табела 3: Резиме резултата анализе преживљавања између $AgeBin$ група за оптимални $cutoff$

AgeBin	n	events	median_survival	S_365
< 65	39	22	433	0.5732721
>= 65	21	16	350	0.4857143

Задатак 7. Потребно је учитати библиотеке за рад са методом *biclustering*. Потребно је учитати податке из предефинисане базе података *Food.sav*, која је дата на дељеном диску. Приликом спровођења анализе максималан број бикластера које алгоритам може да формира ограничити на 25. Параметар $\delta = 1.5$ и $\alpha = 1$ и $\text{method} = \text{BCCC}()$.

Средња вредност променљиве V17 у другом бикластеру је 34.60.

Највећа вредност променљиве V13 у четвртм бикластеру је 69.30.

Медијана променљиве V7 у петом бикластеру износи 31.20.

Минимална вредност променљиве V2 у трећем бикластеру је 100.

У неуређеном Bicluster membership графику променљива V5 се појављује у 5 бикластера.

У сортираном Bicluster membership графику променљива V11 се појављује у 2 бикластера.

Променљива која се појављује у највише бикластера је V3 и појављује се 16 пута.

Практична вредност употребе ове методе огледа се и у проналажењу најзаступљенијих парова заједничких појављивања две варијабле у оквиру различитих бикластера. Стога, у датој матрици података, највећи број заједничког појављивања две варијабле у различитим бикластерима је 5.

Варијабле које се заједно појављују највећи број пута су: V3 и V4, V3 и V6.

Афинитет бикластера дефинише се као однос између средње вредности свих елемената унутар конкретног бикластера и средње вредности истих одабраних варијабли у целој матрици. Бикластер са највећим афинитетом је кластер број 19, а вредност афинитета је 1.42692.

За сваки бикластер израчунајте $\text{within_sd} = \text{sd}()$ свих елемената унутар бикластера. Задржите само бикластере са $\text{n_rows} \geq 6$ и $\text{n_cols} \geq 5$ и пронађите бикластер са најмањом within_sd .

Према задатим критеријумима, најбољи бикластер је 3. Он има 9 редова и 5 колона. Вредност за његов параметар within_sd износи: 2.04868.

Задатак 8. Применом методе логистичке регресије потребно је детаљније истражити матрицу *Arcadis.xlsx*. Прво је потребно од променљиве *Employment* направити категоричку променљиву *EmploymentCategory* са ознакама „low“ за вредности од минималне до 0,3, затим „medium“ од 0,3 до 0,6 и онда „high“ за све веће од 0,6. Друго, потребно је од променљиве *Education* направити категоричку променљиву *EducationCategory* са ознакама „low“ за вредности од минималне до 0,4, затим „medium“ од 0,4 до 0,6 и онда „high“ за све веће од 0,6.

Након тога, креирати варијаблу *HighEmployment*, тако да уколико је *EmploymentCategory* = „high“ онда је вредност 1, а у супротном 0.

Поделити скуп података на тренинг и тест сет у односу 70:30.

Креирати и евалуирати успешност модела логистичке регресије који предвиђа варијаблу *HighEmployment* помоћу варијабли, *crime*, *Drinkingwaterandsanitation*, *Airpollution*, *Energy*, *Greenspace*, *EducationCategory*. Није потребно делити матрицу података на тренинг и тест податке.

Код варијабле *EmploymentCategory* број инстанци категорија од најмање до највеће категорије, респективно је 10, 47, 20.

Код варијабле *EducationCategory* број инстанци категорија од најмање до највеће категорије, респективно је 16, 24, 37.

Када се креира варијабла *HighEmployment*, она броји 57 инстанци за вредност 0, а 20 инстанци за вредност 1.

Статистички значајни предиктори су варијабле:

crime, *Energy*, *Greenspace*, *EducationCategorymedium*.

Оцењена вредност коефицијента за варијаблу *EducationCategoryMedium* је 3.026 и она

јесте статистички значајна. Ако се ова варијабла повећа за 1 мерну јединицу, то значи

да се log – шансе за *HighEmployment* повећавају за 3.026 пута.

Додатно, шансе да варијабла *HighEmployment*=1 су 20.61 пута **веће**/мање за оне градове са *Medium* образовањем у односу на *Low*, када су све остале варијабле фиксне.

Након извршења предикције бинарне категорије задате варијабле *HighEmployment* (узети граничну вредност одлуке „>0,5“), добијају се вредности евалуационих метрика:

Accuracy = 0.7922 *Precision* = 0.6667 *Recall* = 0.4 *F1* = 0.5

Урадите 10 различитих подела на train set / test set (70:30) за *seed* вредности од 123 до 132. За сваки *seed*: тренирајте исти *glm* модел (као што је задат у задатку) и израчунајте на *test set*-у *Accuracy*, *Precision*, *Recall*, *F1* за *threshold* = 0.5. На основу добијених резултата, попуните следећа празна поља:

Seed	<i>Accuracy</i>	<i>Precision</i>	<i>Recall</i>	<i>F1</i>
123	0.7391	1	0.1429	0.25
124	0.6957	0.5	0.2857	0.3636
125	0.6087	0.5	0.3333	0.4
126	0.8261	0.6667	0.4	0.5
127	0.7391	0.25	0.25	0.25
128	0.7826	1	0.2857	0.4444
129	0.8261	0.5	0.25	0.3333
130	0.6957	0.4286	0.5	0.4615
131	0.7391	1	0.25	0.4
132	0.7391	0.25	0.25	0.25

Због уједначеног сагледавања врлина сваког модела, метрика која се користи за оцену, од приказаних, је F1. На основу ње, најбољи модел је онај чија *seed* вредност износи 126.